

Modelos_con_un_algoritmo

José Prince, Andre Jo y Nelson Escalante

2025-04-21

Proyecto 3 Avances 2 Modelos con un algoritmo

Enlace a Github

[[<https://github.com/Jose-Prince/Proyecto3-Mineria-de-datos> (<https://github.com/Jose-Prince/Proyecto3-Mineria-de-datos>)]]

Preprocesamiento de datos

```
datos <- read.csv("merged_output.csv")

# Define base variables
base_vars <- c("DEPREG", "MUPREG", "MESREG", "AÑOREG", "DIAOCU", "MESOCU", "AÑOOCU", "DEPOCU",
"MUPOCU")

# HOM-specific columns
hom_vars <- c(base_vars, "EDADHOM", "PUEHOM", "NACHOM", "ESCHOM", "CIUOHOM")

# MUJ-specific columns
muj_vars <- c(base_vars, "EDADMUJ", "PUEMUJ", "NACMUJ", "ESCMUJ", "CIUOMUJ")

# Create the two dataframes
datos_hom <- datos[, hom_vars]
datos_muj <- datos[, muj_vars]

colnames(datos_hom) <- c(
  base_vars,
  "EDAD", "PUE", "NAC", "ESC", "CIUO"
)

# For datos_muj
colnames(datos_muj) <- c(
  base_vars,
  "EDAD", "PUE", "NAC", "ESC", "CIUO"
)

datos_hom$SEXO <- "HOM"
datos_muj$SEXO <- "MUJ"

datos <- rbind(datos_hom, datos_muj)
```

Variable Respuesta

De acuerdo con nuestros objetivos y la problemática, decidimos utilizar la variable cuantitativa edad tanto de la mujer como del hombre debido a que es un factor clave para entender los patrones y características del divorcio en Guatemala. La edad nos permite analizar en qué etapas de la vida ocurren con mayor frecuencia los divorcios, identificar posibles diferencias entre hombres y mujeres, y explorar si existe una relación entre la edad y la probabilidad de disolución del matrimonio. Por lo tanto, decidimos realizar transformaciones en los datos, unificando las edades de la mujer y del hombre en una sola variable denominada edad. Asimismo, se integró la etnia de ambos en una única variable, con el objetivo de evitar discrepancias al momento del análisis y facilitar la comparación entre ambos géneros.

Por otro lado existen datos NA como el año de ocurrencia con las datos que tienen como registro en 2012 ya que no sabemos si ocurrieron en el año anterior o anteriores lo cual lo generalizamos como el año 2012. Por otro lado en nuestra variable respuesta tiene muchos valores NA lo cual no podemos aplicar llenado de datos con la mediana. Por lo tanto utilizamos un algoritmo forward filling para Completar valores faltantes de forma sencilla cuando se espera que los datos no cambien drásticamente de un punto a otro.

```
##      DEPREG      MUPREG      MESREG      AÑOREG
## Length:163652  Length:163652  Min.   : 1.000  Min.   :2012
## Class :character  Class :character  1st Qu.: 4.000  1st Qu.:2015
## Mode  :character  Mode  :character  Median : 7.000  Median :2019
##                                     Mean  : 6.546  Mean   :2018
##                                     3rd Qu.:10.000  3rd Qu.:2022
##                                     Max.   :12.000  Max.   :2024
##
##      DIAOCU      MESOCU      AÑOOCU      DEPOCU
## Min.   : 1.00  Min.   : 1.000  Min.   :2012  Length:163652
## 1st Qu.: 8.00  1st Qu.: 3.000  1st Qu.:2015  Class :character
## Median :16.00  Median : 6.000  Median :2019  Mode  :character
## Mean   :15.78  Mean   : 6.305  Mean   :2018
## 3rd Qu.:23.00  3rd Qu.: 9.000  3rd Qu.:2021
## Max.   :31.00  Max.   :12.000  Max.   :2023
##
##      MUPOCU      EDAD      PUE      NAC
## Length:163652  Min.   :15.00  Length:163652  Length:163652
## Class :character  1st Qu.:29.00  Class :character  Class :character
## Mode  :character  Median :35.00  Mode  :character  Mode  :character
##                                     Mean   :37.82
##                                     3rd Qu.:44.00
##                                     Max.   :98.00
##                                     NA's   :2
##      ESC      CIUO      SEXO
## Length:163652  Length:163652  Length:163652
## Class :character  Class :character  Class :character
## Mode  :character  Mode  :character  Mode  :character
##
##
##
##
```

```
## [1] 163652      15
```

Por lo tanto, tenemos un total de 15 variables a analizar; en estas tenemos la EDAD, NAC, ESC, CIUO, SEXO y PUE como las variables de Edad tanto hombre y mujer y Etnia para el hombre y mujer. Se observa que en la transformación existen 163652 filas de datos y 11 que son las variables.

Para el conjunto de prueba y entrenamiento observamos que el data set esta ordenado por años, lo cual nuestro proposito es construir un modelo cuyo proposito es predecir en los futuros años. Por lo tanto se tomara para el conjunto de entrenamiento todos los datos que tienen un año de registro menor o igual que 2021. Para los datos de prueba se utilizaria año de registro mayores a 2021.


##	DEPREG	MUPREG	MESREG	AÑOREG	DIAOCU	MESOCU	AÑOOCU	DEPOCU
## 1	Guatemala	Guatemala	8	2015	17	7	2015	Huehuetenango
## 2	Guatemala	Guatemala	6	2016	29	7	2015	Guatemala
## 3	Zacapa	Zacapa	2	2016	8	7	2015	Zacapa
## 4	Guatemala	Guatemala	2	2016	22	12	2015	Guatemala
## 5	Jutiapa	Agua Blanca	2	2015	3	2	2015	Jutiapa
## 6	Guatemala	Guatemala	6	2016	14	10	2015	Jutiapa
##	MUPOCU	EDAD	PUE	NAC	ESC	CIUO	SEXO	
## 1	Huehuetenango	NA	Ignorado	Guatemala	Ninguno	Ignorado	HOM	
## 2	Guatemala	NA	Ignorado	Estados Unidos	Ninguno	Ignorado	HOM	
## 3	Zacapa	46 Mestizo /	Ladino	Guatemala	Ninguno	Ignorado	HOM	
## 4	Villa Nueva	46	Ignorado	Guatemala	Ninguno	Ignorado	HOM	
## 5	Yupiltepeque	46 Mestizo /	Ladino	Guatemala	Ninguno	Ignorado	HOM	
## 6	Jutiapa	46	Ignorado	Guatemala	Ninguno	Ignorado	HOM	

##	DEPREG	MUPREG	MESREG	AÑOREG	DIAOCU	MESOCU	AÑOOCU	
## 46342	Guatemala	Guatemala	6	2022	23	8	2021	
## 46344	Guatemala	Guatemala	1	2022	29	11	2021	
## 46351	Alta Verapaz	San Cristobal	Verapaz	1	2022	23	8	2021
## 46356	Guatemala	Guatemala	4	2022	15	11	2021	
## 46372	Guatemala	Guatemala	1	2022	19	11	2021	
## 46375	Guatemala	Guatemala	1	2022	26	11	2021	
##	DEPOCU	MUPOCU	EDAD	PUE	NAC			
## 46342	Guatemala	Guatemala	36 Mestizo /	Ladino	Guatemala			
## 46344	Guatemala	Guatemala	48 Mestizo /	Ladino	Guatemala			
## 46351	Alta Verapaz	San Cristobal	Verapaz	27	Maya	Guatemala		
## 46356	Guatemala	Chinautla	58 Mestizo /	Ladino	Guatemala			
## 46372	Guatemala	Guatemala	51 Mestizo /	Ladino	Guatemala			
## 46375	Guatemala	Guatemala	43 Mestizo /	Ladino	Guatemala			
##	ESC	CIUO	SEXO					
## 46342	Universitario	<NA>	HOM					
## 46344	Universitario	<NA>	HOM					
## 46351	Primaria	<NA>	HOM					
## 46356	Universitario	<NA>	HOM					
## 46372	Universitario	<NA>	HOM					
## 46375	Universitario	<NA>	HOM					

```
## [1] 36.75274
```


Se observa que el porcentaje del conjunto de prueba es de 36.75% mientras que el porcentaje de entrenamiento es de 63.25

Distribución de la variable respuesta



observa que en la caja de bigotes que los datos atípicos en el conjunto de entrenamientos son las personas mayores a 65 años. Estas podrían representar valores atípicos porque tiene una menor ocurrencia de estos valores en la muestra.

Distribución de la variable respuesta



otro lado observamos que acá los datos atípicos son identificados al tener 62 años o más. Estas podrían representar valores atípicos o simplemente una menor ocurrencia de estos valores en la muestra.